



UNIVERSIDAD DE CHILE

Deep Learning

Deeper, Better, _____ , Stronger than Machine Learning

Valentin Barriere

Universidad de Chile – DCC

CC6204, Primavera 2025

Perceptron Multi Capas y Backpropagacion

Perceptrón multicapa

Outline : Perceptrón multicapa

Perceptrón multicapa

Principio

Ecuaciones y Composicion

Backpropagacion

Principio

Funciones de activación

Outline : Principio

Perceptrón multicapa

Principio

Ecuaciones y Composicion

Backpropagacion

Principio

Funciones de activación

MLP – Presentación

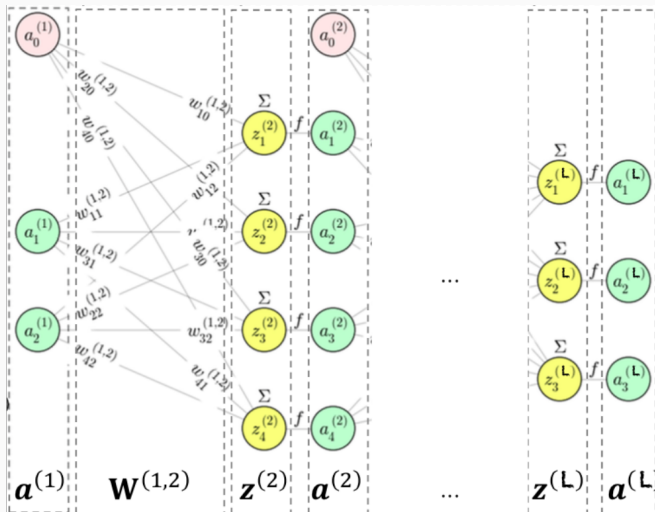


Figure 1: Propagación en un MLP

MLP – Presentación

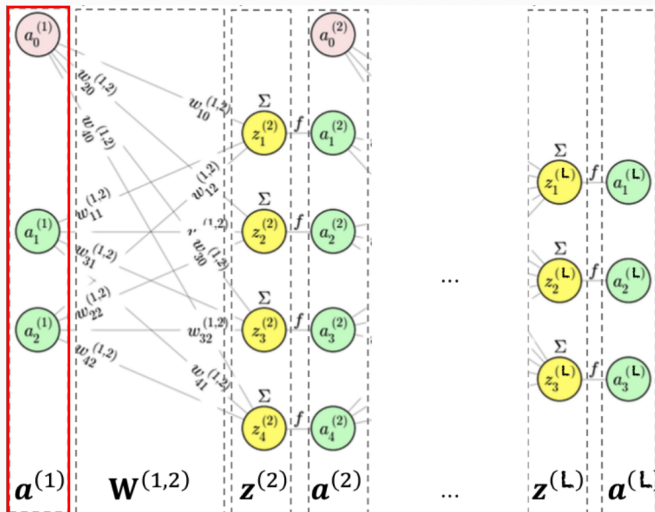


Figure 1: Propagación en un MLP: 1ra capa

MLP – Presentación

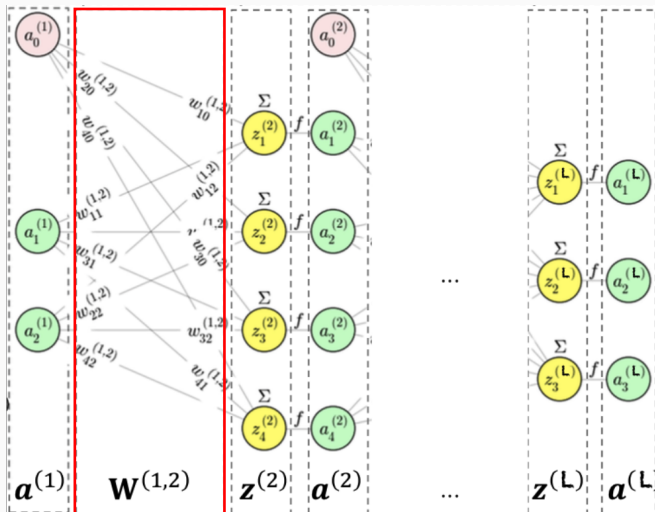


Figure 1: Propagación en un MLP: Matriz de paso

MLP – Presentación

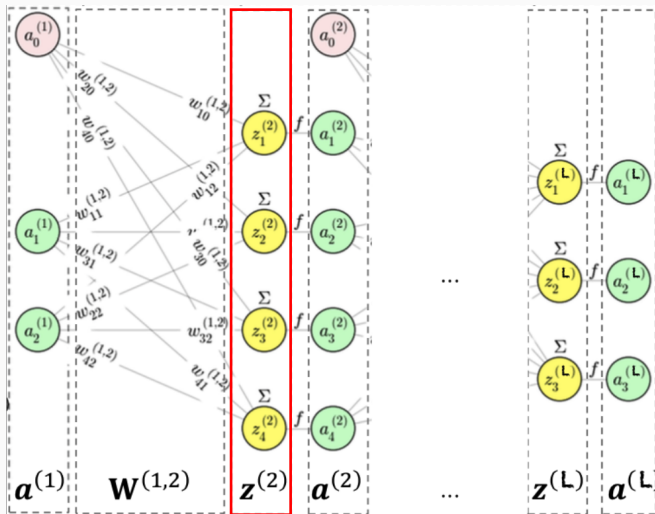


Figure 1: Propagación en un MLP: Entrada 2da capa

MLP – Presentación

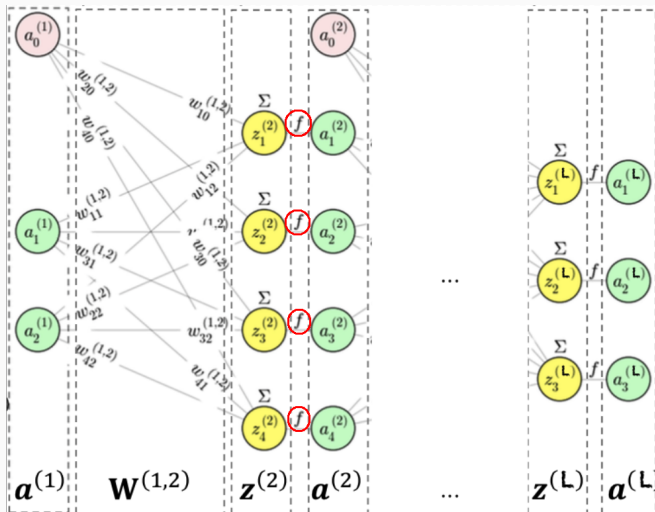


Figure 1: Propagación en un MLP: Activación

MLP – Presentación




Figure 1: Propagación en un MLP: Salida 2da capa

MLP – Presentación




Figure 1: Propagación en un MLP: $\mathbf{a}^{(\ell+1)} = f(\mathbf{W}_{(\ell,\ell+1)}\mathbf{a}^{(\ell)})$

Outline : Ecuaciones y Composicion

Perceptrón multicapa

Principio

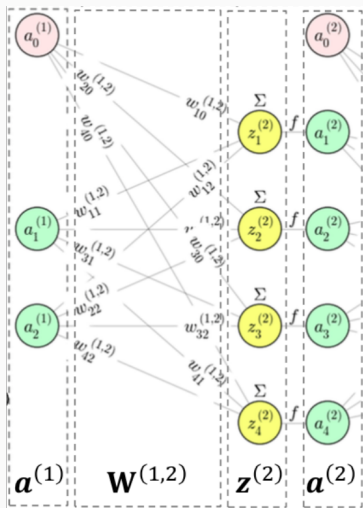
Ecuaciones y Composicion

Backpropagacion

Principio

Funciones de activación

MLP: Principio de una capa



$$a_1^{(2)} = f\left(\sum_j w_{1j}^{(1,2)} a_j^{(1)}\right) = f(\langle \mathbf{W}_1^{(1,2)}, \mathbf{a}^{(1)} \rangle)$$

$$a_2^{(2)} = f\left(\sum_j w_{2j}^{(1,2)} a_j^{(1)}\right) = f(\langle \mathbf{W}_2^{(1,2)}, \mathbf{a}^{(1)} \rangle)$$

$$a_3^{(2)} = f\left(\sum_j w_{3j}^{(1,2)} a_j^{(1)}\right) = f(\langle \mathbf{W}_3^{(1,2)}, \mathbf{a}^{(1)} \rangle)$$

$$a_4^{(2)} = f\left(\sum_j w_{4j}^{(1,2)} a_j^{(1)}\right) = f(\langle \mathbf{W}_4^{(1,2)}, \mathbf{a}^{(1)} \rangle)$$

Por la cappa ℓ , con n_ℓ neuronas:

$$\mathbf{a}^{(\ell)} = (a_0^{(\ell)} \cdots a_{n_\ell}^{(\ell)})$$

$$\mathbf{W}^{(\ell, \ell+1)} = (\mathbf{W}_1^{(\ell, \ell+1)} \cdots \mathbf{W}_{n_k}^{(\ell, \ell+1)})$$

Calculo matricial de una capa, **similar a LogReg!**

Tenemos $\mathbf{a}^{(\ell+1)} = f(\mathbf{z}^{(\ell+1)}) = f(\mathbf{W}^{(\ell, \ell+1)} \mathbf{a}^{(\ell)})$

MLP: Principio

Apilamos capas una sobre otra: la salida de la ℓ ésima capa es la entrada de la $\ell + 1$ ésima capa. Si consideramos la función $h^{(1,2)}$ que representa el paso de la capa 1 a la capa 2.

- $\mathbf{a}^{(2)} = h^{(1,2)}(\mathbf{a}^{(1)})$
- $\mathbf{a}^{(3)} = h^{(2,3)}(\mathbf{a}^{(2)})$
- ...
- $\mathbf{a}^{(L)} = h^{(L-1,L)}(\mathbf{a}^{(L-1)})$
- $\mathbf{a}^{(L)} = h^{(L-1,L)} \circ h^{(L-2,L-1)} \circ \dots \circ h^{(1,2)}(\mathbf{a}^{(1)})$
- $MLP = h^{(L-1,L)} \circ h^{(L-2,L-1)} \circ \dots \circ h^{(1,2)}$ tal que $MLP(\mathbf{a}^{(1)}) = \mathbf{a}^{(L)}$

Una función final como una composición de funciones

El MLP puede verse como una composición de funciones no lineales. Esto permite obtener una función que pasa de los datos de entrada a la salida deseada, que es lo más compleja posible.

Backpropagacion

Outline : Backpropagation

Perceptrón multicapa

Principio

Ecuaciones y Composición

Backpropagation

Principio

Funciones de activación

Outline : Principio

Perceptrón multicapa

Principio

Ecuaciones y Composicion


Backpropagacion

Principio

Funciones de activación


Backpropagacion: Príncipe y regla del Delta

El error en la capa de salida



$$\begin{aligned}\delta^L &= \frac{\partial C}{\partial y'} \sigma'(z^L) \\ &= (y' - y) \cdot \sigma'(z^L)\end{aligned}$$

El error de una capa en términos del error de la siguiente capa



$$\delta^l = (\delta^{l+1} (W^{l+1})^T) \odot \sigma'(z^l)$$

Error va hacia atrás a través de los pesos

Figure 2: El error inicial δ_L se calcula en la salida, y se propaga inversamente

Backpropagacion: Principio y regla del Delta





Figure 2: El error se propaga desde la salida hasta la entrada

$$\delta_i^l = f'(z_i^l) \sum_j w_{ij}^{l+1} \delta_j^{l+1}$$

Back-propagation



1. receive new observation $\mathbf{x} = [x_1 \dots x_d]$ and target y^*
2. **feed forward:** for each unit g_j in each layer $1 \dots L$
compute g_j based on units f_k from previous layer: $g_j = \sigma \left(u_{j0} + \sum_k u_{jk} f_k \right)$
3. get prediction y and error $(y - y^*)$
4. **back-propagate error:** for each unit g_j in each layer $L \dots 1$

(a) compute error on g_j

$$\underbrace{\frac{\partial E}{\partial g_j}}_{\text{should } g_j \text{ be higher or lower?}} = \sum_i \underbrace{\sigma'(h_i)}_{\text{how } h_i \text{ will change as } g_j \text{ changes}} \underbrace{v_{ij}}_{\text{was } h_i \text{ too high or too low?}} \underbrace{\frac{\partial E}{\partial h_i}}_{\text{was } h_i \text{ too high or too low?}}$$

(b) for each u_{jk} that affects g_j

(i) compute error on u_{jk}

$$\frac{\partial E}{\partial u_{jk}} = \underbrace{\frac{\partial E}{\partial g_j}}_{\text{do we want } g_j \text{ to be higher/lower}} \underbrace{\sigma'(g_j)}_{\text{how } g_j \text{ will change if } u_{jk} \text{ is higher/lower}} f_k$$

(ii) update the weight

$$u_{jk} \leftarrow u_{jk} - \eta \frac{\partial E}{\partial u_{jk}}$$

Outline : Funciones de activación

Perceptrón multicapa

Principio

Ecuaciones y Composicion

Backpropagacion

Principio

Funciones de activación

Gradiente Evanesccente

La función de activación f tiene un rol importante en la propagación inversa del gradiente:

$$\delta_i^l = f'(z_i^l) \sum_j w_{ij}^{l+1} \delta_j^{l+1}$$

Si $f'(z_i^l)$ es pequeño, δ_i^l sera pequeño, y el error va a disminuir de manera exponencial.






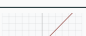

Figure 3: El máximo valor de la derivada ocurre en 0 con valor 0.25, así que el error se divide por 4 en cada capa

Funciones de activación

Función de Heaviside

- En teoría f es la función de Heaviside: $f(z) = \mathbb{1}_{\mathbb{R}_+} = \begin{cases} 0 & \text{si } z < 0 \\ 1 & \text{si } z \geq 0 \end{cases}$
- Problema:** esta función no es derivable.

En la práctica se utilizan funciones derivables como:

Nombre	Gráfico	Ecuación	Valores en $\pm\infty$	Valores derivada en $\pm\infty$
Sigmoide		$f(z) = \frac{1}{1+e^{-z}}$	0; 1	0; 0
Tangente hiperbólica		$f(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$	-1; 1	0; 0
ReLU ¹		$f(z) = \begin{cases} 0 & \text{si } z < 0 \\ z & \text{si } z \geq 0 \end{cases}$	0; z	0; 1
ELU ²		$f(z) = \begin{cases} \alpha(e^z - 1) & \text{si } z < 0 \\ z & \text{si } z \geq 0 \end{cases}$	$-\alpha$; z	0; 1

¹Unidad de Rectificación Lineal

²Unidad Exponencial Lineal

Questions?

